



Université Thiès

Master MSDA

Projet Techniques de Sondages

Realisé par : Khadim CISSE- Seyni KAIRE – Abdoulahi MBENGUE



Exercice 1 :

Probabilité d'inclusion

Soit la population $\{1, 2, 3\}$

Et le plan de sondage : $P(\{1,2\}) = \frac{1}{2}$, $P(\{1,3\}) = \frac{1}{4}$, $P(\{2,3\}) = \frac{1}{4}$

1) Est-ce un sondage aléatoire simple ?

Non, Ce n'est pas un sondage aléatoire simple car tous les échantillons ne sont pas tirés aux mêmes probabilités.

2) Calculons π_1 , π_2 et π_3 les probabilités d'inclusion d'ordre 1

$$\pi_1 = P(\{1,2\}) + P(\{1,3\}) = \frac{1}{2} + \frac{1}{4} = \frac{3}{4}$$

$$\pi_2 = P(\{1,2\}) + P(\{2,3\}) = \frac{1}{2} + \frac{1}{4} = \frac{3}{4}$$

$$\pi_3 = P(\{1,3\}) + P(\{2,3\}) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$$

3) Calculons π_{12} , π_{23} les probabilités d'inclusion d'ordre 2

$$\pi_{12} = P(\{1,2\}) = \frac{1}{2}$$

$$\pi_{23} = P(\{2,3\}) = \frac{1}{4}$$

4) Déterminons l'estimateur π de Y^-

a) si l'échantillon $\{1,2\}$ est tiré

$$Y_1 = 1/N (Y_1/\pi_1 + Y_2/\pi_2) = 4/9(Y_1 + Y_2)$$

b) si l'échantillon $\{1,3\}$ est tiré

$$Y_2 = 1/N (Y_1/\pi_1 + Y_3/\pi_3) = 1/9 (4Y_1 + 6Y_2)$$

c) si l'échantillon $\{2,3\}$ est tiré

$$Y_3 = 1/N (Y_2/\pi_2 + Y_3/\pi_3) = 1/9 (4Y_2 + 6Y_3)$$

5) Vérifions que le π -estimateur est un estimateur sans biais

$$\begin{aligned} E(\bar{Y}) &= \frac{1}{2} \left(\frac{4}{9} (y_1 + y_2) \right) + \frac{1}{4} \left(\frac{1}{9} (4y_1 + 6y_3) \right) + \frac{1}{4} \left(\frac{1}{9} (4y_2 + 6y_3) \right) \\ &= \frac{1}{3} Y_1 + \frac{1}{3} Y_2 + \frac{1}{3} Y_3 \\ &= \frac{1}{3} (Y_1 + Y_2 + Y_3) \\ &= \bar{Y} \end{aligned}$$

Alors le π -estimateur est un estimateur sans biais.

6) Écrivons ce que seraient les probabilités d'échantillon P et les probabilités d'inclusion π pour un sondage aléatoire simple à probabilités égales sans remise.

Avec un sondage aléatoire simple à probabilités égales sans remise, on a pour chaque échantillon la même probabilité d'échantillon :

$$\pi_{12} = \pi_{13} = \pi_{23} = 1/3$$

$$\pi_1 = \pi_2 = \pi_3 = 2/3$$

EXERCICE2

$$\hat{P} \pm 1.96 \sqrt{\text{Var}(\hat{p})}$$

Par suite : on cherche la taille de l'échantillon n telle que :

$$2 \times 1.96 \sqrt{\text{var}(p)} \leq 0.02 \text{ à}$$

$$\text{Or } \text{var}(p) \text{ (sans remise)} = (N - n) p (1 - p)$$

$$/ (N - 1) n \text{ Var}(p) \text{ (avec remise)} = p (1 - p) / n$$

$$P = 3 / 10 ; N = 1500$$

Par application :

Tirage avec remise :

$$2 \times 1.96 \sqrt{p (1 - p) / n} \leq 0.02$$

$$2 \times 1.96 \sqrt{p (1 - p) / n} \leq 2$$

$$\sqrt{p (1 - p) / n} = 2 / 2 \times 196 ; \sqrt{p (1 - p) / n} = 1 / 196$$

$$\sqrt{p (1 - p) / n} = 1/196 \text{ donc}$$

$$(\sqrt{p (1 - p) / n})^2 = (1/196)^2 \text{ donc } p (1 - p) / n \leq 1/196^2 \text{ Or } a/n = 1 / a n \text{ donc on}$$

obtient :

$$n \geq 196^2 p (1 - p) ; n \geq 8067 \text{ (tirage avec remise)}$$

Tirage sans remise :

$$\text{Var}(p) = (N - n) p (1 - p) / (N - 1) n$$

$$(N - n) p (1 - p) / (N - 1) n \leq 1/196^2$$

$n \geq 1962 N p (1 - p) / (N - 1 + 1962 p(1 - p))$; $N = 1500$
 $n \geq 1264$ (tirage sans remise)

2- Que faire si nous ne connaissons pas la proportion :

Si l'on ne connaît pas a priori la proportion de personnes affectées, il faudrait alors remplacer $\text{Var} [\hat{p}]$ par son estimation.

Dans ce cas on obtient :

$\text{Var} (p) = p (1-p) / (n - p)$: tirage avec remise (AR)

$\text{Var} (p) = (N - n) / N * p (1 - p) / n - 1$: tirage sans remise (SR) Notons que le p est un p avec chapeau comme défini ici $\text{Var} [\hat{p}]$.

Une autre approche consisterait à prendre le cas le plus mauvais (ou pessimiste), c'est à dire la valeur théorique de p telle que $\text{Var} [\hat{p}]$ soit le plus grand possible. Clairement le cas le plus pessimiste correspond au choix $p = 0.5$.

Cas sur la consommation des 25 automobilistes au 100km Les hypothèses se traduisent par :

$n=25$; $\bar{x}=8,5$; $S(\text{l'écarttype})=0,8$

Nous utiliserons la table de student à $n-1$ degrés de liberté : $n-1=24$ L'écart type de la population est inconnu:

Si $\alpha = 0,05$ alors sur la table de student $t_{\alpha} = 2,064$ pour $n = 24$

L'intervalle de confiance ayant 95 chances sur 100 de contenir la valeur de la moyenne est : $\bar{X} - t_{\alpha} * S / \sqrt{n-1} \leq m \leq \bar{X} + t_{\alpha} * S / \sqrt{n-1}$

$8,5 - 2,064 * 0,8 / \sqrt{24} \leq m \leq 8,5 + 2,064 * 0,8 / \sqrt{24}$

$8,16 \leq m \leq 8,83$

La probabilité que la consommation moyenne soit comprise entre $[8,16 ; 8,83]$ est égale à 95

%.

2 – pour une marge d'erreurs de 2

décilitres : $2 \text{ dl} = 0,2 \text{ L}$

Or $0,2 = t_{\alpha} * S / \sqrt{n - 1}$

$0,2 (\sqrt{n-1}) = t_{\alpha} * S$ donc $0,2^2 (n-1) = (t_{\alpha} S)^2$

2 par suite : $n = (t_{\alpha} S)^2 / 0,04 + 1$

Avec $t_{\alpha} = 1,96$ pour tout $n > 30$ et $\alpha = 0,05$

$$n = (1,96 * 0,8)^2 / 0,04 + 1 = 62,5$$

Pour $\alpha = 0,01$, dans la table de student $t_{\alpha} = 2,576$ pour tout $n > 30$ $n = (2,576 * 0,8)^2 / 0,04$

$$+ 1 = 106$$

EXERCICE 3 :

1- Donnons une estimation totale des notes dans le district :

$M = 50$; $m = 5$ par suite $f = 5/50 = 1/10 = 0,1$

Dans chaque collège, la note est estimée par :

$T_i = N_i * \bar{y}_i$: on obtient dans les 05 collèges :

$$T_1 = 40 * 12 = 480$$

$$T_2 = 20 * 8 = 160$$

$$T_3 = 60 * 10 = 600$$

$$T_4 = 40 * 12 = 480$$

$$T_5 = 48 * 11 = 528$$

La note totale du district est estimée par :

$$**T = M/m * (T_i) :**$$

$$T = 50/5 (480 + 160 + 600 + 480 + 528) = 22\,480$$

La note totale estimée est à : **22 480**

2 – le nombre d'élèves estimé est de :

$$**N = M/m * (N_i) :**$$

$$N = 50 / 5 (40 + 20 + 60 + 40 + 48) = 2\,080$$

Le nombre d'élèves estimé est de : **2 080**

3-pour $N = 2000$, donnons une estimation de la moyenne et comparons :

$$**Y_{\text{bar}} = 1 / N * T**$$

$$Y_{\text{bar}} = 1/2000 * 22\,480 = 11,24$$

Par conséquent : la moyenne observée sur $N = 50$ est de :

$$: y_{\text{bar}} = 1/50 (10 * 12 + 10 * 8 + 10 * 10 + 10 * 12 + 10 * 11) = 10,6$$

Comparons : y_{bar} n'est un bon estimateur de Y_{bar} : $Y_{\text{bar}} \neq y_{\text{bar}}$

$$S^2_1 = 1/4$$

Calculons la variance de l'estimateur total :

$$(480-449,6)^2 + (160-449,6)^2 + (600-449,6)^2 + (480-449,6)^2 + (528-449,6)^2$$

$$= 28\,620,84$$

$$M^2 (1 - f_i) S_{21} / m = 502 * (1 - 0,1) * 28\,620,84 / 5 = 12\,879\,360$$

Maintenant en posant :

$V_i = N^2 i (1 - f_i) S_{22} / n_i$ Par application :

$$V_1 = 402 * (1 - 10/40) * 1,5 / 10 = 180$$

$$V_2 = 202 * (1 - 10 / 20) * 1,2 / 10 = 24 \text{ donc dans la même logique,}$$

$$V_3 = 480, V_4 = 156, V_5 = 364,8.$$

Ainsi en multipliant par M/m, on obtient que la quantité cherchée est égale

$$: M/m (v_1 + v_2 + v_3 + v_4 + v_5)$$

$$= 50 / 5 (180 + 24 + 480 + 156 + 364,5) = 10 * 1204,8 = 12\,048$$

L'estimation de la variance de l'estimateur du total est égale : $\text{Var}(T) = 12\,879\,360 + 12\,048 = 12\,891\,408$.

On peut en déduire la variance de la moyenne :

$$\text{Var}(\bar{y}) = 1/N^2 * \text{Var}(T) = 1/2000^2 * 12\,891\,408 = 3,22$$

5 - Comparaison avec un sondage aléatoire simple à probabilité est égale sur les mêmes données :

$$\bar{Y} = \bar{y} = 10,6 ; n=50 \text{ et } N=2000.$$

Donc le taux de sondage est égal à :

$$f = 50/2000 = 0,25$$

L'estimation de la variance de l'estimateur de la moyenne est égale à : $\text{Var} Y = (1-f) * S^2/n$, ou S^2 est la variance corrigée de l'échantillon.

Dans notre échantillon de taille 50, on a :

Variance totale = variance inter + variance intra

Calculons maintenant chaque terme qui compose la variance totale :

$$\text{Variance inter} = 1/50 (10*122 + 10*82 + 10*102 + 10*122 + 10*112) - 10,6^2 = 2,24$$

$$\text{Variance intra} = 1/50 * 0,9 * 10 (1,5 + 1,2 + 1,6 + 1,3 + 2,0) = 1,368$$

$$\text{Donc Variance totale} = 2,24 + 1,368 = 3,608$$

$$\text{La variance corrigée est de : } S^2 = 50 / (50 - 1) * 3,608 = 3,68$$

$$\text{Et } \text{Var}(\bar{Y}) = (1 - 0,25) * 3,68 / 50 = 0,07.$$

La précision d'un sondage aléatoire simple à probabilité égale sans remise est supérieure à celle d'un sondage à plusieurs degrés :

Pour un intervalle de confiance de 95%, on a :

Plus ou moins : $1,96\sqrt{\text{var}(\bar{Y})}$ donc on a les précisions suivantes 0,52 et 3,25.

Exercice 4:

1) le nombre maximum d'erreurs qu'on peut acceptation dans cet échantillon sans remettre en cause le niveau d'acceptation

***POUR $n=200$ on a :**

$$\text{Nombre d'erreurs} = 0,05 * 200 = 10 \text{ erreurs}$$

Même question avec $n=400$, $n=600$ et $n=1000$

***POUR $n=400$ on a :**

Nombre d'erreurs $= 0,05 \times 400 = 20$ erreurs

***POUR $n=600$ on a :**

Nombre d'erreurs $= 0,05 \times 600 = 30$ erreurs

***POUR $n=1000$ on a :**

Nombre d'erreurs $= 0,05 \times 1000 = 50$ erreurs

2) le nombre d'enregistrement supplémentaire qu'on doit effectuer pour que l'hypothèse soit acceptée

$$0,05 \times n = (7+4) \Rightarrow n = 11 / 0,05 = 180$$

Donc on doit faire 180 enregistrements supplémentaires pour que l'hypothèse d'un niveau d'acceptation de 5% puisse être raisonnablement retenue